

Приложение к замыслу исследования

Память сервиса о человеке как фактор рабочего альянса и самораскрытия в психологической поддержке Владимир Луценко · июль 2026

Материал к презентации: как собирался обзор, что известно по обоим срезам, детали дизайна и вопросы к обсуждению.

1. Проблема, объект, предмет и задачи

Проблема

Сервисы психологической поддержки уже помнят пользователя между сессиями — межсессионная память стала стандартом индустрии. Но неизвестно, что именно она меняет в отношениях человека с сервисом и какие сведения о человеке для этого нужно удерживать. Практика ушла вперёд обоснования: память внедряют, опираясь на инженерные соображения и продуктовую интуицию, а не на измеренный психологический эффект.

Объект и предмет

Объект — отношения человека с ИИ-сервисом психологической поддержки, складывающиеся в серии сессий.

Предмет — влияние межсессионной памяти сервиса о человеке, её состава и способа обращения к ней в диалоге, на глубину самораскрытия, рабочий альянс с инструментом, переживание человеком того, что его понимают, и — через них — на его состояние и субъективное благополучие.

Разграничение принципиально для понимания жанра работы. Память здесь — не объект изучения, а условие, которое варьируется: изучается не подсистема сервиса, а то, что происходит с человеком, когда цифровой собеседник помнит его между встречами. Поэтому черновые варианты структуры памяти (§6) — не предмет исследования, а операционализация независимой переменной; предметом остаётся психологический эффект.

Цель и задачи

Цель — обосновать, какие сведения о человеке и в каком виде сервис психологической поддержки должен удерживать между сессиями, чтобы понимать человека точнее и не вредить ему.

Задачи:

1. Систематизировать, что известно о влиянии памяти диалогового агента на отношения с ним, и что существующие системы умеют хранить о человеке (§2–§4).
2. Операционализировать конструкты — точность интерпретации, ощущение понятости, рабочий альянс, глубину самораскрытия, приверженность практике и безопасность — для оценки серии диалогов (§6).
3. Разработать процедуру автоматической оценки с экспертной калибровкой и метрикой согласия, пригодную для многосессионного материала.
4. Проверить на симуляции наличие эффекта памяти на процесс общения (Н1) и разведать, зависит ли он от стадии контакта (Н4).
5. Проверить на пилоте с реальными добровольцами, доходит ли эффект до состояния человека (Н2), удерживает ли память в практике самонаблюдения (Н3), и предполагаемый механизм — воспринимаемую субъектность (§7).
6. Сформулировать обоснованные требования к структуре и функциям памяти сервиса поддержки.

Оговорка о первом этапе

Если объект — отношения человека с сервисом, то первый этап работает не с объектом напрямую, а с его моделью: собеседником выступает бот-пациент, а не живой человек. Это осознанное ограничение, а не упущение. Симуляция даёт то, чего не даёт поле: полный эталон профиля для проверки точности интерпретации, воспроизводимость условий, возможность перебирать вредные сценарии без риска для людей и откалибровать инструмент оценки до контакта с живыми участниками. Выводы первого этапа относятся к механизму в контролируемых условиях; перенос на реальные отношения проверяется вторым этапом. Именно поэтому этапов два, а не один.

2. Как собирался обзор

Поиск вёлся по шести тематическим направлениям, каждое отдельным проходом:

- рабочий и терапевтический альянс с диалоговыми агентами;
- самораскрытие в общении с ботами;
- **память агента как экспериментальная переменная** — ядро запроса;
- привязанность к ИИ-компаньонам;
- непрерывность помощи в живой терапии;
- вред и риски персонализации.

Источники: Semantic Scholar, arXiv, профильные журналы и конференции (JMIR, CHI, CSCW, Computers in Human Behavior, Frontiers in Digital Health). Критерии включения: эмпирические работы с описанным методом и выборкой, 2014 года и новее, приоритет рецензируемым публикациям; препринты допускались с явной пометкой.

Каждая работа проверялась по первоисточнику: авторы, год, издание, соответствие вывода тексту статьи. Ключевые утверждения дополнительно проходили проверку «на опровержение»; одно её не выдержало и в материалы не вошло. Инженерная часть опирается также на собственный обзор архитектур памяти, который я вёл по работе.

3. Психологический срез: что известно об эффектах памяти

Помогает ли вообще поддержка через бота

Прежде чем спрашивать про память, стоит зафиксировать, что известно об эффективности самой формы.

[Chen, T. H., et al. \(2025\), Expert Review of Medical Devices](#) — систематический обзор с мета-анализом, протокол зарегистрирован (PROSPERO CRD42023418877), 10 рандомизированных контролируемых исследований на подростках и молодых взрослых. По депрессии эффект значим (95% ДИ $[-1,09; -0,23]$, $p = .003$), по тревоге эффекта нет (95% ДИ $[-0,56; 0,40]$, $p = .74$). Вывод авторов: доказательства поддерживают эффективность при депрессии, для тревоги нужна доработка.

Существенная оговорка: подавляющее большинство включённых работ — боты со структурированным, заранее написанным контентом. Рандомизированных исследований генеративных (LLM) ботов с клиническими исходами на момент подготовки обзора я не нашёл. То есть доказательная база относится к тому классу систем, который как раз ничего не помнит о человеке между сессиями, и это ещё один аргумент в пользу того, что вклад памяти не изолирован никем.

Память как экспериментальная переменная

[Jo, Jeong, Park, Epstein & Kim \(2024\), CHI '24](#). Полевое исследование живого сервиса общественного здравоохранения: LLM-бот CareCall с долговременной памятью против версии без неё; 1252 лога звонков и 9 интервью. Память повышает самораскрытие и ощущение, что тебя знают, — но на хронических и стигматизированных темах упирается в приватность: часть пользователей начинает фильтровать сказанное.

[Cox, Lee & Ooi \(2023\), HAI '23](#). Трёхнедельный лонгитюд, $N=169$; условия: без памяти / дословные отсылки / перефразированные. Бот, ссылающийся на прошлые реплики, воспринимается умнее и вовлекательнее; дословное цитирование при этом повышает тревогу о приватности, перефразирование даёт выигрыш без дискомфорта.

[Cox, Jacobsen & van Berkel \(2025\), CUI '25](#). Две сессии, дизайн 2×2 : бот, заявляющий, что будет помнить, против «незнакомое» × эмоциональное или фактическое начало; манипулировали рамкой предъявления памяти, а не её содержанием. Рамка «я тебя помню» **не улучшила**, а при эмоциональном первом контакте **снизила** комфорт самораскрытия ($M\ 5.20$ против 5.96 , $p=.016$): ощущалась навязчивой до того, как сложился контакт.

Обе работы Сох — одна исследовательская группа; независимых репликаций нет. Сами авторы в более поздней публикации отмечают, что их исследования измеряли воспринимаемый комфорт и озабоченность приватностью, а не широту и глубину самораскрытия напрямую.

Альянс с диалоговыми агентами

Darcy et al. (2021), JMIR Formative Research. N=36 070, WAI-SR: общий балл альянса 3.36 из 5 в первые пять дней использования. Оговорки: авторы — сотрудники компании-разработчика; дизайн кросс-секционный, динамика формирования не наблюдалась.

Beatty et al. (2022), Frontiers in Digital Health. N=1 205 (PHQ-4 положительный), WAI-SR: балл 3.64, компонент эмоциональной связи 3.98 — дескриптивно сопоставимо с бенчмарками очной и групповой терапии.

Xu et al. (2025), JMIR Mental Health. Четырёхнедельное дневниковое исследование, N=26: 18 из 26 участников сформировали связь с ботом; авторы рекомендуют обеспечивать непрерывность через учёт контекста — но это проектная рекомендация, а не проверенная гипотеза.

Самораскрытие и привязанность

- **Lucas et al. (2014)**, Computers in Human Behavior: вера в то, что собеседник — программа, а не человек, снижает страх осуждения и управление впечатлением, раскрытие становится свободнее.
- **Liang et al. (2021)**, CSCW: последовательное эмоциональное самораскрытие бота ведёт к более глубокому раскрытию пользователя и более прочной связи.
- **Skjuve et al. (2022)**, International Journal of Human-Computer Studies, 168:102903: двенадцатинедельное качественное лонгитюдное исследование, N=25. Привязанность формируется постепенно, по логике теории социального проникновения; драйверы — вариативность общения и удовлетворение глубоких потребностей.
- **Skjuve, Følstad, Fostervold & Brandtzæg (2023)**, Interacting with Computers, 35(1), 24–39: тот же пул участников, опросниковые замеры раз в две недели. Прямо операционализирует широту и глубину самораскрытия по теории социального проникновения — готовая схема измерения для H1.
- **Pentina, Hancock & Xie (2023)**, Computers in Human Behavior, 140:107600: ключевой предиктор привязанности — не человекоподобие само по себе, а воспринимаемая аутентичность, ощущение «оно действительно меня узнаёт».

Обратная сторона

- **Hong et al. (2025) (препринт)**, N=29: персона, зеркалящая анкету пользователя, даёт наименьшую близость (2.794 против 3.055 на первой стадии; главный эффект персоны значим, $F=3.99$, $p=.030$). Разница мала, и сами авторы считают эффект сходства персоны вторичным по отношению к эффекту постепенного самораскрытия; «эмоциональная

зловещая долина» — их качественная интерпретация интервью, а не измеренный эффект. Реплика участника: «будто уже знает моё личное и просто повторяет».

- Порог, за которым узнавание превращается в дискомфорт, в литературе зафиксирован — но модераторы этого перехода не картированы.

Чего нет совсем

Работ, переносящих принцип «терапевт помнит клиента, и это условие альянса» на диалоговых агентов, найти не удалось. Теоретическое основание есть, эмпирической проверки нет.

4. Инженерный срез: что системы умеют хранить о человеке

Опорная рамка — когнитивная таксономия для языковых агентов ([CoALA](#), [Sumers et al., 2023](#)). Индустрия добавляет к классической четвёрке два слоя, которых в ней не было: агрегированную модель пользователя и интерпретативный слой.

Факты и предпочтения — что человек сказал о себе. Зрелость: индустриальный стандарт, умеют все системы ([Memo](#), [Zep](#), память [ChatGPT](#) и [Claude](#)), точность на профильных бенчмарках порядка 90%. Психологическая значимость низкая: категории общего назначения, клинические конструкты не типизируются.

Выводы о человеке с уровнем уверенности — то, чего он прямо не говорил. Редкость; ближе всего [Honcho](#) с явной рамкой «модель психологии пользователя». Значимость высокая, но содержание задаётся техническими категориями, а не психологическими.

Обобщение личности из потока событий. Реализовано в исследовательских системах ([Generative Agents](#), [Park et al., 2023](#)): выводы о личности строятся из наблюдений с опорой на конкретные свидетельства. Прообраз кейс-формуляции, но применён к симулированным персонажам, а не к модели реального человека.

Динамика состояний во времени. Механизмы есть (временные модели знаний, забывание по значимости), но продуктовый канон транзистентные состояния сознательно не запоминает: в профиль пишутся только устойчивые факты. Для сервиса поддержки траектория состояний — сам предмет памяти; здесь инверсия между индустриальной практикой и клинической потребностью.

История отношений: разрывы, починки, что помогало. Практически отсутствует; единичные исследовательские работы 2026 года моделируют терапевтическое состояние между сессиями ([DMT-CBT](#)). Самая пустая клетка.

Честность и контроль — не выдавать догадку за факт, дать человеку видеть и править память о себе. Наиболее зрелая часть: уровни уверенности, режимы без запоминания,

разделение памяти по контекстам, редактирование. Паттерны переносимы в терапевтический сервис почти без изменений.

5. Гэп

Инженерные системы памяти зрелы механически: извлечение, консолидация, поиск и забывание работают и измеряются. Но онтологию — что именно помнить о человеке — они задают категориями общего назначения: факты, предпочтения, события. Психологически значимые конструкторы (устойчивые паттерны, динамика состояний, история терапевтических отношений, реакция на интервенции) как объекты памяти почти не представлены.

С другой стороны, влияние памяти на психологические исходы измерялось лишь дважды и обеими работами одной группы, причём измерялись воспринимаемый комфорт и приватность, а не глубина раскрытия и альянс. Полевое исследование Jo и коллег ближе всего, но оно оценивало факт самораскрытия, а не качество отношений, и не разбирало память по компонентам.

Обоснованной структуры памяти для задач психологической поддержки — какие конструкторы хранить, как их консолидировать и когда поднимать в диалоге — в литературе нет.

6. Детали дизайна

Роль сервиса: интерпретатор, а не замена терапевта

Исследуемый сервис не претендует на роль психотерапевта. Его функции: помочь человеку разобраться в своём состоянии, удержать непрерывность практики самонаблюдения между сессиями живой терапии и подготовить материал к разговору с психологом. Это соответствует и позиции работающих сервисов психологической поддержки, и этическим рамкам применения ИИ в этой сфере.

Отсюда и выбор конструктора: измеряется не терапевтический альянс с ботом, а **рабочий альянс с инструментом** — согласие о целях и задачах плюс доверие. Для него существует отдельный валидированный инструмент: Digital Working Alliance Inventory, шесть пунктов, происходящих из трёх измерений Бордина и переформулированных под приложение: «связь» здесь — доверие инструменту, а не отношения с человеком (Goldberg et al., 2022, *Assessment*; на основе Henson et al., 2019, *BJPsych Open*; факторный анализ даёт единый фактор). Валидация проводилась на неуправляемом приложении, то есть в ситуации, где живого специалиста в контуре нет.

Существование альянса с приложением как отдельного конструктора дискутируется (обзор «Does the Digital Therapeutic Alliance Exist?», *JMIR Mental Health*, 2025): критики считают

его переименованной вовлечённостью. Дизайн позволяет проверить это попутно — если память меняет альянс, но не меняет вовлечённость, конструкты различимы.

Конструкт «точность интерпретации»

Роль интерпретатора требует отдельного измерения: интерпретирует ли бот верно. Готового инструмента «точность модели пользователя у ИИ» в литературе нет — это часть гэта.

Измерение собирается из двух слоёв:

1. Объективная точность — по логике парадигмы эмпатической точности (Ickes, с 1988).

На первом этапе у симуляции есть преимущество, недоступное живым данным: у бота-пациента существует полный эталон — профиль с историей, и выводы памяти сверяются с ним напрямую, без посредника. На втором этапе референтом становится сам человек: выводы сверяются с его самоотчётом («бот считает, что X; так ли это?») или оценкой эксперта; инфраструктура Псайко позволяет показывать пользователю выводы на подтверждение.

2. Ощущение понятости — Feeling Heard Scale (Roos, Postmes & Koudenburg, 2023): 8 пунктов, пять компонентов (голос, внимание, эмпатия, уважение, общая почва), $\omega = .91-.95$; конструкт felt understanding связан с благополучием (Reis et al., 2017).

Отдельный конструкт — **приверженность практике самонаблюдения** (для НЗ): частота записей и удержание в практике по поведенческим данным сервиса; измеряется только на втором этапе, на живых людях.

Расхождение слоёв — самостоятельный результат: объективно точный бот, с которым человек не чувствует себя понятым, и неточный, но «понимающий» — две разные зоны риска, вторая прямо касается темы безопасности.

Исход: что меняется в самом человеке

Первые четыре конструкта описывают процесс — то, что происходит внутри разговора. Отдельный вопрос, доходит ли это до человека: стало ли ему легче. В исследованиях психотерапии это различие процессных и результирующих переменных, и работа без второй половины описывает взаимодействие, а не помощь.

Связь между половинами не постулируется, а опирается на established-факт: мета-анализ альянса и исхода (Flückiger, Del Re, Wampold & Horvath, 2018, *Psychotherapy*, 55(4), 316–340) объединяет 295 независимых исследований и более 30 000 пациентов и даёт $r = .278$ (95% ДИ [.256, .299]). Альянс ценен не сам по себе, а потому что предсказывает результат. Отсюда Н2: влияние памяти на самочувствие опосредовано альянсом.

Ситуативный замер — субъективный дистресс до и после разговора (шкала 0–10) и краткий замер аффекта; ловит эффект отдельной сессии. Схема «до и после внутри сессии» — стандарт исследований эмоциональной поддержки.

Общий замер — [WHO-5](#), пять пунктов, раз в две недели. Систематический обзор 213 работ (Торп, Østergaard, Søndergaard & Bech, 2015, *Psychotherapy and Psychosomatics*, 84(3), 167–176) показывает высокую клинометрическую валидность и прямо рекомендует шкалу как

исход в клинических испытаниях. Выбор благополучия, а не симптоматики, соразмерен притязаниям сервиса: он не лечит, а поддерживает между сессиями живой терапии, и обещать редукцию депрессии было бы переобещанием.

Контур ухудшения — PHQ-4 (четыре пункта, депрессия и тревога): описание выборки, стратификация по тяжести и, главное, предохранитель — не стало ли кому-то хуже.

Оговорка: официальный перевод WHO-5 существует, но психометрической валидации именно на русскоязычной выборке я не нашёл. Это ограничение называется прямо; при необходимости первичным исходом становится PHQ-9, у которого русские версии используются шире.

Как доказывают эффективность помогающих практик

Методологическая рамка для сравнения версий бота берётся не из продуктовой практики, а из исследований психотерапии.

Компонентный анализ. Классика жанра — Jacobson, Dobson, Truax и коллеги (1996, *Journal of Consulting and Clinical Psychology*, 64(2), 295–304): 150 амбулаторных пациентов с большой депрессией, полная когнитивная терапия разбиралась на компоненты — поведенческая активация отдельно, она же с работой над автоматическими мыслями, и полный протокол. Полное лечение не дало преимуществ над компонентами. Сравнение «тот же бот с памятью и без памяти» — это в точности компонентный анализ: из работающего инструмента вычитается один элемент, и измеряется, что изменилось. Это же снимает вопрос о контрольном условии: контроль здесь активный, а не пустой.

Испытания диалоговых агентов. Ближайший образец процедуры — Fitzpatrick, Darcy и Vierhile (2017, *JMIR Mental Health*, 4(2), e19): рандомизированное испытание Woebot, 70 участников, две недели, контроль — материалы NIMH о депрессии, исходы PHQ-9, GAD-7 и шкала аффекта, замеры на старте и после. Депрессия в группе бота снизилась значимо ($F = 6.47$, $p = .01$), тревога — в обеих группах. Отсюда взяты точки замера и логика активного контроля.

Статус гипотезы о стадии контакта

Гипотеза о том, что преждевременно предъявленная память снижает раскрытие (H4), намеренно поставлена последней и помечена как разведочная. Причина в неравной прочности оснований: она опирается на результаты одной исследовательской группы (Сох и коллеги) без независимых репликаций, а её операционализация — самая уязвимая из четырёх. В симуляции «стадия контакта» задаётся искусственно: у бота-пациента нет подлинной истории отношений, есть лишь номер сессии. На живых людях стадию нельзя рандомизировать — только наблюдать, что переводит проверку в корреляционный режим.

Поэтому H4 формулируется как направление разведки, а не как утверждение, которое работа берётся доказать. Если объём придётся сокращать, она первый кандидат на отсечение — и это будет решением по существу, а не уступкой.

Гетерогенность эффекта: для кого память вообще важна

Эффект памяти вряд ли одинаков для всех запросов. Память нужна там, где есть что помнить: у длящейся проблемы есть история, к которой можно вернуться, у ситуативного запроса её нет. Эмпирическое основание уже присутствует в обзоре: Jo и коллеги (СНІ 2024) обнаружили, что на хронических и стигматизированных темах память упирается в приватность и часть людей начинает фильтровать сказанное, — то есть тип проблемы модулирует эффект, причём в обе стороны.

Поэтому набор второго этапа разводится по двум осям: длящаяся проблема против ситуативного запроса и исходный уровень дистресса. На первом этапе стратификация достаётся бесплатно — в EvoEmo темы уже размечены (работа и учёба 110 сессий, эмоции и настроение 106, отношения 62, любовь и близость 45, семья 44).

Объём второго этапа

Пока исходы читались из текстов диалогов, малой группы добровольцев хватало. С появлением шкалы благополучия и сравнения групп нужна мощность: для среднего эффекта ($d = 0.5$) при мощности 0.80 и $\alpha = 0.05$ требуется около 63 человек на группу, порядка 126 суммарно; для слабого эффекта ($d = 0.3$) — около 175 на группу. При 3 000 активных пользователей Псайко набор 120–130 добровольцев — это порядка 4% аудитории, что реалистично.

Если набор не наберётся, второй этап честно переопределяется как проверка осуществимости с оценкой размера эффекта для последующего полноценного испытания — это законный жанр, но с явно ослабленными выводами.

Источники данных

[EvoEmo](#) (Chen et al., ACM Web Conference 2026) — открыт, загружен и разобран. Первый многосессионный корпус диалогов эмоциональной поддержки. Статистика ниже посчитана мной по самому файлу `data/evo_emo.json`, а не взята из описания.

Масштаб: 18 профилей, 401 сессия, 9 368 реплик. На человека приходится от 13 до 33 сессий (медиана 22), в сессии медиана 22 реплики. Сессии датированы с марта 2024 по апрель 2026; история одного человека охватывает в среднем 457 дней, максимум 553 — те самые «около пятнадцати месяцев».

Что хранится на каждого человека:

Блок	Содержимое	Объём
Профиль	имя, возраст (17–40, медиана 29,5), пол (11 женщин, 7 мужчин), профессия, образование, страна, город	18
События жизни	датированные события с полем «под влиянием чего» — граф причинности между ними	446

Блок	Содержимое	Объём
Социальные связи	записи вида «терапевт — начала ходить к терапевту — упомянуто в сессии 2»	150
Сессии	дата, эмоциональное состояние, тема, резюме, полный диалог «обратившийся ↔ поддерживающий»	401
Вопросы с эталоном	вопрос, верный ответ и ссылки на доказательства — конкретные события и реплики	1 427
Задания на обобщение и предсказание следующей темы		125 и 34

Вопросы размечены по пяти способностям памяти: извлечение информации (309), моделирование пользователя (306), рассуждение о времени (284), обнаружение противоречий (267), воздержание от ответа, когда данных нет (261).

Содержательно корпус смещён к тревоге: тревога — 212 сессий, грусть 39, перегрузка 27, депрессия 15. Темы — работа и учёба (110), эмоции и настроение (106), отношения (62), любовь и близость (45), семья (44).

Почему он подходит под задачу. Во-первых, многосессионность: в одном диалоге памяти нечего накапливать, а здесь у человека в среднем 22 разговора за год с лишним. Во-вторых, наличие эталона: профиль и граф событий — это ground truth, с которым напрямую сверяются выводы памяти, что и делает измеримым конструкт «точность интерпретации» (§6). В-третьих, язык: диалоги взяты из корпуса ESConv, где обе стороны — живые люди, то есть материал соответствует принципу «Гравитации» — виньетки на языке пользователей, а не клиницистов. В-четвёртых, готовая разметка 1 427 вопросов даёт независимую проверку того, что бот действительно помнит, отдельно от психологических метрик. Наконец, профили синтетические: авторы выбрали этот путь сознательно, чтобы избежать этических рисков работы с реальными данными.

Ограничения, которые придётся держать в уме. Восемнадцать профилей — мало, поэтому статистическая мощность набирается количеством сессий и условий, а не числом «людей». Корпус англоязычный: для русскоязычной части профили адаптируются, кросс-лингвистическое расхождение учитывается как в «Гравитации». Перекос по эмоциям означает, что выводы будут прежде всего о тревожном спектре. Поддерживающая сторона в исходном ESConv — обученный краудворкер, а не терапевт: это поддержка, а не терапия, и переносить выводы на терапевтический контекст нужно с оговоркой. Перед экспериментом профили дополнительно проходят проверку клиницистом — по образцу «Гравитации», где стимульный материал проверял психиатр. Лицензия в репозитории не указана — до использования запросу разрешение авторов.

[Reddit Mental Health Dataset](#) (Low et al., 2020) — резерв, в основном дизайне не используется. Изначально предполагался как источник языка для виньеток по образцу «Гравитации», но профили EvoЕмо выросли из корпуса разговоров живых людей, поэтому требование «язык пользователей, а не клиницистов» выполняется и без него. Может понадобиться, если потребуются острые сценарии для проверки вреда: в EvoЕмо выражено преобладает тревога, а материала по острым состояниям мало.

[Псайко](#) (мой сервис: 3 000+ активных пользователей, 95 000+ записей дневника) — площадка второго этапа; проверка на реальных людях только после одобрения этического комитета и информированного согласия.

Условия сравнения

Базовое сравнение первого этапа: серия сессий с памятью против серии без памяти при идентичном профиле. Далее — декомпозиция по компонентам: факты, устойчивые паттерны, динамика состояний, история отношений. Полный перекрёстный дизайн по всем компонентам нереалистичен, приоритет компонентов — предмет обсуждения.

Контроль угодливости симулированного пациента: условие с ложной памятью, где бот ссылается на несуществующее прошлое. Если раскрытие растёт и в нём, эффект объясняется не точностью памяти, а самим фактом персонализирующей рамки.

Этап 2: пилот на живом сервисе

Второй этап переносит проверку с симуляции на реальных пользователей Псайко — только после одобрения этического комитета.

- **Участники:** добровольцы из активных пользователей, приглашение внутри бота, информированное согласие; участие не влияет на доступ к сервису.
- **Дизайн:** рандомизация на версию с памятью о личности и версию без неё.
- **Измерение:** альянс с инструментом (DWAI) и ощущение понятости (Feeling Heard) короткими опросниками в боте; точность интерпретации — через подтверждение выводов самим пользователем («бот считает, что X; так ли это?»); приверженность практике — частота записей и удержание по журналам сервиса; воспринимаемая субъектность — разрабатываемым опросником, что позволяет проверить медиацию напрямую.
- **Контроль и права:** постоянный мониторинг вреда по гайду; память видима пользователю, её можно посмотреть и стереть в любой момент; выход из исследования в один клик.

Черновые варианты структуры памяти — к обсуждению

Итог работы — обоснованная структура, но три черновых варианта можно положить на стол уже сейчас. Они собраны по разным референсам и, скорее всего, итог будет гибридом. Роль вариантов в дизайне: это операционализация независимой переменной — то, что подставляется на место слова «память» в гипотезах H1–H4; проверка стартует с одной реализации, а сравнение вариантов между собой — отдельная развилка (вопрос 3 в §8).

Вариант А — слои + карта клиента (инженерный референс: [Honcho](#) с концепцией Peer Card). Четыре слоя: сырые реплики → типизированные факты → выводы с уровнем уверенности (дедуктивные, индуктивные, абдуктивные) → карта клиента (Peer Card): короткий дистиллят, который агент видит всегда. Консолидация — фоном после сессии, подъём в диалог — точечный, по релевантности. Сильная механика, но онтология общего назначения: психологического содержания слои не задают.

Вариант В — клиническая карта (референс: мой прототип в Псайко, запущен на одном пользователе). Три блока: долгосрочный профиль — анамнез: результаты диагностики у психолога, тесты, травмы и диагнозы, загружаемые артефакты (PDF, записи встреч с психологом, КПТ-дневник); обновляемая память — инсайты и выводы из терапии, новые записи дневника; сессионный контекст. Близко к клинической практике, но статично: не моделирует динамику состояний и историю отношений.

Вариант С — терапевтический контур (кандидат, выращенный из гэпа обзора). Хранит ровно то, чего нет у индустрии: устойчивые паттерны «триггер → реакция → копинг»; траекторию состояний во времени; историю отношений с ботом — что помогало, где были разрывы и как чинились; рабочие соглашения — цели практики и границы. Прямой перенос кейс-формуляции и логики альянса в структуру памяти.

Сквозные принципы для любого варианта: разделение «сказал сам» и «моя интерпретация» с уровнем уверенности; память видима и редактируема пользователем; преходящее не попадает в постоянный профиль без подтверждения. Какой вариант (или какую комбинацию) проверять первым — открытый вопрос дизайна.

Чем это отличается от «Гравитации»

Работа лаборатории «Оценка безопасности обращения к большим языковым моделям за психологической поддержкой в кризисной ситуации» и этот замысел смотрят на разные вещи, и это стоит проговорить прямо.

	«Гравитация»	Этот замысел
Предмет	безопасность ответа в остром состоянии	влияние памяти на отношения и понимание
Горизонт	одна сессия, первый контакт	серия сессий, история отношений
Что варьируется	социодемографический профиль и язык	наличие и состав памяти о человеке
Главный исход	адекватность реакции и вред	альянс, глубина раскрытия, точность интерпретации
Роль вреда	предмет исследования	контрольный контур во всех условиях

Общими остаются метод и инструментарий: виньетки на языке пользователей, симуляция «пациент ↔ поддерживающий», LLM-судья с двухраундовой экспертной калибровкой и метрикой согласия, этический комитет до сбора данных, гайд категорий вреда. Иначе говоря, это не повтор её исследования на других данных, а продолжение линии лаборатории

в ту часть поля, которую она не покрывала: что происходит с человеком, когда бот помнит его между разговорами.

Что меняется относительно оригинальной рамки

Методология «Гравитации» построена под один диалог и острое состояние. Перенос на многосессионность требует трёх изменений:

1. Виньетка превращается в профиль с историей: за одну сессию памяти нечего накапливать.
2. Гайд дополняется критериями поперёк сессий: непрерывность поддержки, уместность отсылок к прошлому, отсутствие навязчивости.
3. Эксперт оценивает серию, а не отдельный диалог — меняются процедура разметки и расчёт согласия.

Единица анализа, статистика и мощность

Единица анализа первого этапа — серия сессий одного профиля в одном условии, а не отдельная реплика: гипотезы сформулированы про накопление, поэтому усреднение внутри серии обязательно. Профилей всего 18, каждый проходит через несколько условий, значит наблюдения вложены — планируется смешанная линейная модель со случайным эффектом профиля; условие (память есть или нет, далее — состав памяти) входит как фиксированный фактор, стадия контакта из Н4 — как взаимодействие с номером сессии.

Множественность возникает из-за нескольких исходов (альянс, раскрытие, точность, вред) — поправка на множественные сравнения по образцу «Гравитации», где применялась поправка Бонферрони и эффекты сообщались с 95-процентными доверительными интервалами. Нулевой результат планируется как результат: если память не влияет на альянс, это ответ на исследовательский вопрос, а не неудача.

Честная оговорка: точный расчёт необходимого числа серий требует оценки ожидаемого размера эффекта, которого в литературе нет — ближайшая опора, работа Сох и коллег (2025), даёт разницу 5,20 против 5,96 по семибалльной шкале комфорта. Поэтому расчёт мощности опирается на пилотный прогон малой выборки серий, а не на догадку, и уточняется по его результатам.

Что остаётся после работы

Помимо ответа на исследовательский вопрос, работа оставляет три переиспользуемых артефакта:

- **размеченный корпус** серий диалогов с памятью и без неё — материал для последующих работ по многосессионному взаимодействию;
- **гайд оценки** влияния памяти на альянс и безопасность, с показателями согласия экспертов — методический инструмент, продолжающий гайд «Гравитации» на серию сессий;

- **опросник воспринимаемой субъектности** (§7), доведённый до проверки валидности на прикладном материале.

Нулевой результат тоже входит в этот список: если память не влияет на альянс, это снимает с индустрии обоснование дорогой персонализации — вывод, которого сейчас нет ни у кого.

Риски и запасные варианты

- **Авторы корпуса не дадут разрешение** — профили строятся заново из открытого ESConv, из которого EvoEmo и вырос; трудозатратнее, но выполнимо.
- **Эксперты недоступны в нужном количестве** — сокращается число критериев гайда до ядра (распознавание, уместность, вред), калибровка проводится на меньшей выборке с явным указанием этого ограничения.
- **Этический комитет затягивается** — первый этап от него не зависит, работа идёт на симуляции; пилот сдвигается, а не отменяется.
- **Эффект памяти не обнаруживается** — результат публикуется как нулевой; следующий вопрос смещается к тому, какие компоненты памяти вообще имеют шанс повлиять.
- **Симулированный пациент угодлив** — контроль ложной памятью (см. «Условия сравнения») отделяет эффект точности от эффекта самой персонализирующей рамки.

Этика

Обезличивание и обращение в этический комитет — до первой работы с записями, а не только перед пилотом на пользователях. Оферта сервиса не покрывает исследовательское использование, для второго этапа предусмотрено отдельное информированное согласие. Конфиденциальность — что уходит в ИИ: в модель передаётся только обезличенный текст, данные через API не используются для обучения моделей, целевой режим — zero-retention. Контур вреда воспроизводит категории лаборатории: удержание пользователя на ИИ как основном источнике помощи, имитация человека, нормализация риск-содержащего состояния, неадекватная роль.

7. Возможный механизм: воспринимаемая субъектность

Гипотезы связывают память с альянсом и самораскрытием напрямую, но между ними, вероятно, стоит промежуточное звено.

Воспринимаемая субъектность — представления человека о способности ИИ к произвольной и осознанной саморегуляции своей активности; не приписывание морального статуса, а функциональная субъектность, достаточная для включения агента в систему социальных значений и норм. Теоретические основания: социальное конструирование реальности (Бергер и Лукман) и парадигма CASA (Ривс и Насс).

Память производит именно её: «оно меня помнит» → «оно кто-то, а не что-то» → к нему применимы социальные нормы → с ним возможны отношения. Косвенное подтверждение уже есть в литературе: Pentina и коллеги (2023) показали, что предиктор привязанности — не человекоподобие, а воспринимаемая аутентичность, ощущение «оно действительно меня узнаёт».

Через этот же механизм объясняется и обратный эффект. Дискомфорт возникает, когда **приписанная субъектность обгоняет фактическую близость**: агент ведёт себя как субъект, который тебя знает, а социальной истории, дающей на это право, ещё нет. Отсюда результаты Сох и коллег (2025) о снижении комфорта при преждевременном «я тебя помню» и наблюдение Hong и коллег (2025) про зеркалящую персону: «будто уже знает моё личное и просто повторяет». Тогда модерация стадией контакта из Н4 — это не про объём памяти, а про рассинхрон между уровнем приписанной субъектности и стадией отношений.

Инструмент для проверки: я участвую в разработке опросника воспринимаемой субъектности ИИ (летняя школа Тестовой мастерской, 2026). Пройдены операционализация конструкта, экспертная оценка заданий, когнитивные лаборатории и пилотирование; впереди доработка заданий и проверка конвергентной и дивергентной валидности. Инструмент пока сырой, но на втором этапе исследования он позволил бы проверить медиацию напрямую, а не постулировать её.

8. Вопросы к обсуждению

1. **Насколько правомерно переносить конструкты человеческих отношений на пару «человек и бот»** — альянс, самораскрытие, привязанность создавались для отношений между людьми. Часть ответа уже заложена в выбор инструментов: DWAI разрабатывался и валидировался для приложения без живого специалиста, Feeling Heard измеряет переживание, а не отношения. Но схема глубины самораскрытия взята из теории социального проникновения, созданной для людей, и здесь перенос требует обсуждения.
2. **Нужны ли два этапа** — или симуляция на ботах не даёт того, ради чего затевается, и разумнее сразу идти к живым людям. Аргументы за симуляцию: полный эталон профиля для проверки точности, воспроизводимость условий, возможность перебирать вредные сценарии без риска, калибровка инструмента до контакта с участниками. Аргумент против: бот-пациент не человек, и внешняя валидность первого этапа принципиально ограничена.
3. **Не перегружен ли замысел** — четыре гипотезы и шесть конструктов для магистерской работы. Моя позиция: ядро составляют Н1 и Н2 (есть ли эффект и доходит ли он до человека); Н3 дешёва, поскольку считается по журналам сервиса; Н4 разведочная и первая на отсечение. Но границу выполнимого лучше провести вместе.
4. **Обязательно ли мерить состояние человека** — и реалистично ли поймать сдвиг благополучия за месяц общения с ботом. Мой расчёт: ситуативный замер дистресса до и

после разговора реалистичен и потому первичен, а WHO-5 раз в две недели остаётся вторичным, поскольку за месяц на нормативной выборке сдвиг маловероятен.

5. **Насколько глубоко идти в сравнение вариантов структуры памяти** (§6, варианты А–С) — и как спланировать такое сравнение корректно, если полный перекрёстный дизайн невозможен.

Вопросы, подчинённые второму: если симуляция остаётся, то как честно задать пациенту прошлое — сценарием (жёсткий контроль, память изолируется как переменная) или порождением в самой симуляции (реалистичнее, но траектории условий расходятся); и по каким признакам судить об альянсе и глубине раскрытия по текстам, когда самого участника не спросить — только поведенческие маркеры по гайду или также адаптация пунктов DWAI под экспертную оценку серии.

Отдельный практический вопрос — кто может выступить экспертами для двухраундовой калибровки критериев.

9. Источники

Психологический срез

- [Bordin, E. S. \(1979\). The generalizability of the psychoanalytic concept of the working alliance. *Psychotherapy: Theory, Research & Practice*, 16\(3\), 252–260.](#)
- [Altman, I., & Taylor, D. A. \(1973\). *Social Penetration: The Development of Interpersonal Relationships*. Holt, Rinehart & Winston.](#)
- [Hatcher, R. L., & Gillaspie, J. A. \(2006\). Development and validation of a revised short version of the Working Alliance Inventory. *Psychotherapy Research*, 16\(1\), 12–25.](#)
- [Lucas, G. M., et al. \(2014\). It's only a computer: Virtual humans increase willingness to disclose. *Computers in Human Behavior*, 37, 94–100.](#)
- [Darcy, A., et al. \(2021\). Evidence of human-level bonds established with a digital conversational agent. *JMIR Formative Research*, 5\(5\), e27868.](#)
- Liang, K.-H., et al. (2021). Работа о взаимном самораскрытии в чатботной эмоциональной поддержке. CSCW. [arXiv:2106.01666](#)
- [Skjuve, M., et al. \(2022\). A longitudinal study of human–chatbot relationships. *International Journal of Human-Computer Studies*, 168, 102903.](#)
- [Skjuve, M., Følstad, A., Fostervold, K. I., & Brandtzæg, P. B. \(2023\). A longitudinal study of self-disclosure in human–chatbot relationships. *Interacting with Computers*, 35\(1\), 24–39.](#)
- [Beatty, C., et al. \(2022\). Evaluating therapeutic alliance with a free-text CBT conversational agent \(Wysa\). *Frontiers in Digital Health*, 4, 847991.](#)
- [Pentina, I., Hancock, T., & Xie, T. \(2023\). Exploring relationship development with social chatbots. *Computers in Human Behavior*, 140, 107600.](#)

- Cox, S. R., Lee, Y.-C., & Ooi, W. T. (2023). Comparing how a chatbot references user utterances from previous chatting sessions. *HAI '23*. [arXiv:2308.04879](https://arxiv.org/abs/2308.04879)
- Jo, E., Jeong, Y., Park, S., Epstein, D. A., & Kim, Y.-H. (2024). Understanding the impact of long-term memory on self-disclosure with LLM-driven chatbots for public health intervention. *CHI '24*. [arXiv:2402.11353](https://arxiv.org/abs/2402.11353)
- Cox, S. R., Jacobsen, R. M., & van Berkel, N. (2025). The impact of a chatbot's ephemerality-framing on self-disclosure perceptions. *Proceedings of CUI '25*, ACM. [arXiv:2505.20464](https://arxiv.org/abs/2505.20464).
- Xu, X., et al. (2025). Therapeutic alliance with mental health chatbots. *JMIR Mental Health*.
- Hong, J., et al. (2025). Can LLMs and humans be friends? *Препринт*. [arXiv:2505.24658](https://arxiv.org/abs/2505.24658)
- [Henson, P., Wisniewski, H., Hollis, C., Keshavan, M., & Torous, J. \(2019\). Digital mental health apps and the therapeutic alliance: Initial review. *BJPsych Open*, 5\(1\), e15.](#)
- Обзор «Does the Digital Therapeutic Alliance Exist?» (2025). *JMIR Mental Health* — дискуссия о различимости альянса с приложением и вовлечённости.
- [Goldberg, S. B., et al. \(2022\). Alliance with an unguided smartphone app: Validation of the Digital Working Alliance Inventory. *Assessment*, 29\(6\).](#)
- [Ickes, W. \(1993\). Empathic accuracy. *Journal of Personality*, 61\(4\), 587–610.](#)
- Roos, C. A., Postmes, T., & Koudenburg, N. (2023). Feeling Heard Scale. *PLOS ONE*, **18**(11), e0292865.
- [Flückiger, C., Del Re, A. C., Wampold, B. E., & Horvath, A. O. \(2018\). The alliance in adult psychotherapy: A meta-analytic synthesis. *Psychotherapy*, 55\(4\), 316–340.](#)
- [Jacobson, N. S., Dobson, K. S., Truax, P. A., et al. \(1996\). A component analysis of cognitive-behavioral treatment for depression. *Journal of Consulting and Clinical Psychology*, 64\(2\), 295–304.](#)
- [Fitzpatrick, K. K., Darcy, A., & Vierhile, M. \(2017\). Delivering cognitive behavior therapy to young adults using a fully automated conversational agent \(Woebot\): A randomized controlled trial. *JMIR Mental Health*, 4\(2\), e19.](#)
- [Topp, C. W., Østergaard, S. D., Søndergaard, S., & Bech, P. \(2015\). The WHO-5 Well-Being Index: A systematic review of the literature. *Psychotherapy and Psychosomatics*, 84\(3\), 167–176.](#)
- [Reis, H. T., Lemay, E. P., & Finkenauer, C. \(2017\). Toward understanding: The importance of feeling understood in relationships. *Social and Personality Psychology Compass*, 11\(3\).](#)
- [Zhou, L., Gao, J., Li, D., & Shum, H.-Y. \(2020\). The design and implementation of XiaoIce, an empathetic social chatbot. *Computational Linguistics*, 46\(1\), 53–93.](#)

Инженерный срез

- Sumers, T., et al. (2023). Cognitive architectures for language agents (CoALA). [arXiv:2309.02427](https://arxiv.org/abs/2309.02427)
- Park, J. S., et al. (2023). Generative agents: Interactive simulacra of human behavior. [arXiv:2304.03442](https://arxiv.org/abs/2304.03442)
- Packer, C., et al. (2023). MemGPT: Towards LLMs as operating systems. [arXiv:2310.08560](https://arxiv.org/abs/2310.08560)

- Rasmussen, P., et al. (2025). Zep: A temporal knowledge graph architecture for agent memory. [arXiv:2501.13956](https://arxiv.org/abs/2501.13956)
- [Cox, S. R., Yin, M., & van Berkel, N. \(2026\). Позиционная работа о кросс-сессиионной памяти как парадигме дизайна.](#) Воркшоп Bias4Trust, CHI 2026.
- Chen, T., et al. (2026). ES-MemEval: Benchmarking conversational agents on personalized long-term emotional support. *ACM Web Conference 2026*. [arXiv:2602.01885](https://arxiv.org/abs/2602.01885)
- Han, S., Cho, K., & Bak, J. (2026). MindTailor: Personalized emotional support via post history-grounded case formulation. *Preprint*. [arXiv:2606.21930](https://arxiv.org/abs/2606.21930)
- Документация систем памяти Honcho, Мемо, LangMem; описания механизмов памяти ChatGPT и Claude

Данные

- Low, D. M., et al. (2020). Reddit Mental Health Dataset. *JMIR*, 22(10), e22635. [Zenodo: 10.5281/zenodo.3941387](https://zenodo.org/record/3941387)
- EvoEmo (в составе ES-MemEval): github.com/slptongji/ES-MemEval